

Self-Supervised GNNs for Recommendation under Data Sparsity

ΕΡΓΑΣΙΑ ΣΤΟ ΜΑΘΗΜΑ “DEEP LEARNING”

Ιούνιος 2026

Κίνητρο και Στόχοι

Κίνητρο:

- Τα recommender systems υποφέρουν από data sparsity
- Τα Graph Neural Networks αξιοποιούν τη δομή του user-item γράφου
- Το Self-Supervised Learning μπορεί να βελτιώσει τα embeddings

Ερευνητικά Ερωτήματα:

- Βελτιώνει το SSL την απόδοση των recommender systems;
- Είναι καλύτερα τα graph augmentations ή τα embedding perturbations;
- Πώς επηρεάζονται από την αραιότητα;
- Γενικεύουν σε μεγαλύτερα datasets;

Ορισμός Προβλήματος 1/2

Recommender Systems

Στόχος:

- Πρόβλεψη προτιμήσεων χρηστών
- Παραγωγή εξατομικευμένων προτάσεων

Πρόβλημα:

- Οι περισσότεροι χρήστες έχουν λίγες αλληλεπιδράσεις
- Τα δεδομένα είναι sparse

Μπορεί το Self-Supervised Learning να βελτιώσει τα recommendations σε sparse δεδομένα;




Ορισμός Προβλήματος 2/2

Recommender Systems → Link Prediction

Χρήστες → κόμβοι

Ταινίες → κόμβοι

Ratings (θετικές, ≥ 4) → ακμές



Γιατί Graphs;

Επιτρέπουν τη διάδοση πληροφορίας μεταξύ χρηστών και αντικειμένων

LightGCN

- *Message Passing* πάνω στον *User-Item Graph* ($User \rightarrow Movie \rightarrow User \rightarrow Movie$)
- *State-of-the-art baseline* για *recommendation*
- *Απλό και αποτελεσματικό* για *recommendation*

Χαρακτηριστικά:

- *Χωρίς feature transformations*
- *Χωρίς activation functions*
- *Μόνο propagation*

Self-Supervised Learning

Πρόβλημα: Sparse δεδομένα $\Rightarrow$ αδύναμα embeddings

Λύση: Contrastive Learning $\Rightarrow$ Μαθαίνει embeddings που παραμένουν παρόμοια κάτω από μικρές μεταβολές του γράφου

Στόχος:

- ίδιος κόμβος $\rightarrow$ κοντά embeddings
- διαφορετικοί κόμβοι $\rightarrow$ μακρινά embeddings

Edge SSL

- *Edge Dropout*
- *Δημιουργεί 2 διαφορετικούς γράφους*

Graph 1 vs Graph 2

SimGCL

- *Ο γράφος παραμένει ίδιος*
- *Προστίθεται θόρυβος στα embeddings*

Embedding + Noise

Κεντρική Διαφορά: Graph perturbation vs Embedding perturbation

Προτεινόμενες Μέθοδοι

Popularity-Aware Edge Dropout

κλασικό Edge Dropout → όλες οι ακμές έχουν την ίδια πιθανότητα αφαίρεσης

Πρόταση:

- Δημοφιλή αντικείμενα → μεγαλύτερο dropout
- Σπάνια αντικείμενα → μικρότερο dropout

Οι ακμές δημοφιλών αντικειμένων είναι λιγότερο κρίσιμες, καθώς υπάρχει ήδη αρκετή διαθέσιμη πληροφορία.

Degree-Adaptive Noise Injection

SimGCL → όλα τα embeddings δέχονται τον ίδιο θόρυβο

Πρόταση:

- Η ένταση του perturbation εξαρτάται από τον βαθμό του κόμβου.

Dense-Aware: περισσότερο perturbation σε κόμβους υψηλού βαθμού

Sparse-Aware: περισσότερο perturbation σε κόμβους χαμηλού βαθμού

Combined Adaptive SSL

Συνδυασμός των 2 προηγούμενων ιδεών: Popularity-Aware Edge Dropout & Degree-Adaptive Noise Injection

Μεθοδολογία

Datasets

- MovieLens 100K
- MovieLens 1M

Sparsity Levels

- 100% δεδομένα
- 50% δεδομένα
- 25% δεδομένα
- 10% δεδομένα

Candidate Generation

Για κάθε χρήστη:

- 1 πραγματική (θετική) ταινία
- 99 αρνητικές ταινίες

Train/Test Split

- 1 θετική αλληλεπίδραση ανά χρήστη στο test set
- Οι υπόλοιπες θετικές αλληλεπιδράσεις στο train set

Metrics

HitRate@10

Ποσοστό χρηστών για τους οποίους η σωστή ταινία εμφανίζεται στο Top-K

Recall@10

Ποσοστό των σχετικών αντικειμένων που ανακτώνται στις πρώτες 10 θέσεις

NDCG@10

ποσοστό που λαμβάνει υπόψη αν βρέθηκε το σωστό αντικείμενο ΚΑΙ τη θέση του στην κατάταξη

Κύρια Αποτελέσματα (MovieLens 100K)

Μέθοδος	HR@10	NDCG@10
BPR-MF	0.585	0.332
<i>LightGCN</i>	0.575	0.315
Edge SSL	0.625	0.359
SimGCL	0.622	0.350
Adaptive Noise Dense	0.618	0.353

+8.7% HR@10
ΣΕ ΣΧΕΣΗ ΜΕ
LIGHTGCN

Αξιολόγηση Προτεινόμενων Μεθόδων

Μέθοδος	HR@10	NDCG@10
Popularity-Aware Edge SSL	0.612	0.359
Adaptive Noise Dense	0.618	0.353
Adaptive Noise Sparse	0.616	0.350
Combined Adaptive SSL	0.617	0.356

ADAPTIVE NOISE DENSE ΠΕΤΥΧΕ ΤΗΝ ΚΑΛΥΤΕΡΗ ΕΠΙΔΟΣΗ (HR@10 = 0.618).

Sparsity Analysis (MovieLens 100K)

- Όσο αυξάνεται η αραιότητα, μειώνεται η απόδοση όλων των μοντέλων.
- Οι embedding-based SSL μέθοδοι είναι πιο ανθεκτικές σε μέτρια sparsity.
- Σε ακραίο sparsity (10%), το SSL χάνει μέρος της αποτελεσματικότητάς του.


BEST METHOD:

100% → EDGE SSL

50% → ADAPTIVE NOISE DENSE

25% → SIMGCL

10% → LIGHTGCN




Generalization Study (MovieLens 1M)

Μέθοδος	HR@10	NDCG@10
BPR-MF	0.679	0.395
<i>LightGCN</i>	0.652	0.376
Edge SSL	0.664	0.401
SimGCL	0.694	0.411
Adaptive Noise Dense	0.696	0.412

ADAPTIVE NOISE DENSE

- HR@10: 0.652 → 0.696 (+6.7%)
- NDCG@10: 0.376 → 0.412 (+9.6%)

Απόδοση vs Υπολογιστικό Κόστος



Η Adaptive Noise Dense και το SimGCL συνδυάζουν υψηλή απόδοση με σημαντικά χαμηλότερο υπολογιστικό κόστος.

Method Runtime

BPR-MF: 3 min

LightGCN: 78 min

SimGCL: 109 min

Adaptive Noise Dense: 105 min

Edge SSL: 230 min

— Συμπεράσματα

- Οι περισσότερες SSL μέθοδοι βελτιώνουν συστηματικά την απόδοση του LightGCN.
- Οι SSL μέθοδοι είναι ιδιαίτερα αποτελεσματικές σε μέτρια επίπεδα αραιότητας.
- Οι embedding perturbation προσεγγίσεις γενικεύουν καλύτερα σε μεγαλύτερα datasets.
- Η Adaptive Noise Dense πέτυχε την καλύτερη συνολική απόδοση στο MovieLens 1M.
- Το SimGCL και η Adaptive Noise Dense προσφέρουν το καλύτερο trade-off ποιότητας και κόστους

— Περιορισμοί & Μελλοντική Εργασία

- Αξιολόγηση μόνο σε MovieLens datasets
- Εξέταση μόνο contrastive SSL τεχνικών
- Δεν πραγματοποιήθηκε hyperparameter optimization
- Μελλοντική αξιολόγηση σε μεγαλύτερα και πιο sparse datasets
- Εφαρμογή adaptive SSL σε άλλες GNN αρχιτεκτονικές
- Αυτό συνήθως αρέσει πολύ στους καθηγητές γιατί δείχνει κριτική σκέψη.

Thank you