

Self-Supervised Graph Neural Networks for Recommendation under Data Sparsity

Εργασία στο μάθημα "Deep Learning"

Ξενάκη Μαρία

Ιούνιος 2026

Περιεχόμενα

Εισαγωγή	1
Θεωρητικό Υπόβαθρο	2
Μεθοδολογία	4
Πειραματική Μελέτη	8
Αποτελέσματα Συζήτηση	10
Συμπεράσματα	16
Βιβλιογραφία	16

Εισαγωγή

Τα συστήματα συστάσεων αποτελούν βασικό πεδίο εφαρμογής της μηχανικής μάθησης, καθώς χρησιμοποιούνται για την πρόβλεψη των προτιμήσεων των χρηστών και την παραγωγή εξατομικευμένων προτάσεων. Παραδοσιακές προσεγγίσεις, όπως το Matrix Factorization, μαθαίνουν λανθάνουσες αναπαραστάσεις χρηστών και αντικειμένων με βάση τις παρατηρούμενες αλληλεπιδράσεις. Ωστόσο, οι αλληλεπιδράσεις αυτές μπορούν φυσικά να μοντελοποιηθούν ως διμερής γράφος, όπου οι χρήστες και τα αντικείμενα αποτελούν δύο διαφορετικούς τύπους κόμβων και οι ακμές αντιστοιχούν σε θετικές αλληλεπιδράσεις.

Σε αυτό το πλαίσιο, τα Graph Neural Networks έχουν χρησιμοποιηθεί με επιτυχία για recommendation tasks, καθώς επιτρέπουν τη διάδοση πληροφορίας μεταξύ χρηστών και αντικειμένων. Το LightGCN αποτελεί μία απλοποιημένη και αποτελεσματική GNN αρχιτεκτονική, η οποία αφαιρεί μη γραμμικούς μετασχηματισμούς και feature transformations, εστιάζοντας αποκλειστικά στη διάδοση embeddings πάνω στον user-item γράφο.

Παρόλα αυτά, ένα βασικό πρόβλημα στα recommender systems είναι η αραιότητα των δεδομένων. Πολλοί χρήστες έχουν λίγες αλληλεπιδράσεις, ενώ πολλά αντικείμενα εμφανίζονται σπάνια. Αυτό οδηγεί σε ασταθείς ή μη επαρκώς εκπαιδευμένες αναπαραστάσεις. Για την αντιμετώπιση αυτού του προβλήματος, πρόσφατες προσεγγίσεις ενσωματώνουν self-supervised learning, κυρίως μέσω contrastive learning, ώστε το μοντέλο να μαθαίνει πιο robust embeddings.

Στην παρούσα εργασία μελετάται η επίδραση διαφορετικών self-supervised training strategies πάνω στο LightGCN για recommendation. Συγκεκριμένα, συγκρίνονται graph-based augmentations, όπως το Edge Dropout, με embedding-level perturbations, όπως το SimGCL-style noise injection. Επιπλέον, προτείνονται adaptive παραλλαγές που προσαρμόζουν την ένταση του augmentation με βάση τη δημοτικότητα των αντικειμένων ή τον βαθμό των κόμβων.

Η βασική ερευνητική ερώτηση της εργασίας είναι κατά πόσο οι self-supervised στρατηγικές εκπαίδευσης μπορούν να βελτιώσουν την απόδοση ενός GNN-based recommender, ιδιαίτερα σε συνθήκες αραιότητας. Για τον σκοπό αυτό πραγματοποιούνται πειράματα στα MovieLens 100K και MovieLens 1M datasets, καθώς και sparsity analysis σε διαφορετικά επίπεδα διαθέσιμων αλληλεπιδράσεων.

Οι βασικές συνεισφορές της παρούσας εργασίας είναι οι εξής:

- Υλοποίηση και αξιολόγηση SSL-based recommender systems βασισμένων στο LightGCN.
- Σύγκριση graph-based και embedding-based SSL στρατηγικών.
- Πρόταση adaptive augmentation τεχνικών βασισμένων στη δημοτικότητα αντικειμένων και στον βαθμό των κόμβων.
- Εκτενής μελέτη της επίδρασης της αραιότητας μέσω sparsity experiments.
- Αξιολόγηση της δυνατότητας γενίκευσης των μοντέλων στο μεγαλύτερο MovieLens 1M dataset.

Θεωρητικό Υπόβαθρο

Recommender Systems και Matrix Factorization

Τα recommender systems έχουν ως στόχο την πρόβλεψη των προτιμήσεων των χρηστών και την παραγωγή εξατομικευμένων προτάσεων. Στα collaborative filtering συστήματα, οι προτάσεις βασίζονται αποκλειστικά στις αλληλεπιδράσεις χρηστών και αντικειμένων, χωρίς να απαιτούνται επιπλέον χαρακτηριστικά περιεχομένου.

Μία από τις πιο επιτυχημένες κλασικές προσεγγίσεις είναι το Matrix Factorization (MF). Η βασική ιδέα είναι η παραγοντοποίηση του πίνακα αλληλεπιδράσεων σε δύο πίνακες λανθανουσών αναπαραστάσεων: έναν για τους χρήστες και έναν για τα αντικείμενα. Κάθε χρήστης και κάθε αντικείμενο αναπαρίστανται ως ένα διάνυσμα χαμηλής διάστασης και η συνάφεια μεταξύ τους υπολογίζεται μέσω του εσωτερικού γινομένου των αντίστοιχων embeddings.

Στην εργασία χρησιμοποιείται η παραλλαγή Bayesian Personalized Ranking Matrix Factorization (BPR-MF), η οποία εκπαιδεύεται μέσω pairwise ranking. Για κάθε χρήση, το μοντέλο μαθαίνει να δίνει υψηλότερο score σε αντικείμενα με τα οποία έχει αλληλεπιδράσει σε σχέση με τυχαία μη αλληλεπιδρασμένα αντικείμενα.

Παρότι το Matrix Factorization αποτελεί ένα ιδιαίτερα ισχυρό baseline, δεν αξιοποιεί τη δομή του γράφου που προκύπτει από τις αλληλεπιδράσεις χρηστών και αντικειμένων.

Graph-Based Recommendation

Οι αλληλεπιδράσεις χρηστών και αντικειμένων μπορούν να μοντελοποιηθούν ως ένας διμερής γράφος (bipartite graph). Στον γράφο αυτό υπάρχουν δύο κατηγορίες κόμβων:

- Κόμβοι χρηστών -> users
- Κόμβοι αντικειμένων -> items

Μία ακμή μεταξύ ενός χρήστη και ενός αντικειμένου υποδηλώνει ότι πραγματοποιήθηκε κάποια θετική αλληλεπίδραση, όπως μία υψηλή βαθμολογία ή μία αγορά.

Η γραφική αναπαράσταση επιτρέπει την αξιοποίηση πληροφοριών γειτονίας. Για παράδειγμα, δύο χρήστες που έχουν αλληλεπιδράσει με παρόμοια αντικείμενα είναι πιθανό να έχουν παρόμοιες προτιμήσεις, ενώ δύο αντικείμενα που προτιμώνται από παρόμοιους χρήστες είναι πιθανό να παρουσιάζουν ομοιότητες.

Τα Graph Neural Networks επιτρέπουν τη διάδοση πληροφορίας πάνω στον γράφο μέσω message passing, δημιουργώντας embeddings που ενσωματώνουν πληροφορία από γειτονικούς κόμβους.

LightGCN

Το LightGCN αποτελεί μία απλοποιημένη αρχιτεκτονική Graph Neural Network σχεδιασμένη ειδικά για collaborative filtering. Σε αντίθεση με τα κλασικά GCNs, αφαιρεί τους μετασχηματισμούς χαρακτηριστικών και τις μη γραμμικές συναρτήσεις ενεργοποίησης, διατηρώντας αποκλειστικά τη διαδικασία διάδοσης πληροφορίας μεταξύ γειτονικών κόμβων.

Η βασική ιδέα του μοντέλου είναι ότι οι αναπαραστάσεις χρηστών και αντικειμένων μπορούν να βελτιωθούν μέσω επαναλαμβανόμενης ανταλλαγής πληροφορίας πάνω στον γράφο αλληλεπιδράσεων. Σε κάθε επίπεδο διάδοσης, οι κόμβοι ενημερώνουν τα embeddings

τους λαμβάνοντας πληροφορία από τους γειτονικούς κόμβους τους. Με τον τρόπο αυτό οι τελικές αναπαραστάσεις περιέχουν όχι μόνο άμεση πληροφορία από τις αλληλεπιδράσεις του χρήστη, αλλά και έμμεση πληροφορία που προκύπτει από τη συνολική δομή του γράφου.

Ένα επιπλέον χαρακτηριστικό του LightGCN είναι ότι το τελικό embedding κάθε κόμβου προκύπτει από τον συνδυασμό των embeddings όλων των επιπέδων διάδοσης. Η προσέγγιση αυτή επιτρέπει στο μοντέλο να αξιοποιεί ταυτόχρονα πληροφορία διαφορετικών αποστάσεων μέσα στον γράφο και έχει αποδειχθεί ιδιαίτερα αποτελεσματική σε προβλήματα recommendation.

Λόγω της απλότητάς του και της υψηλής απόδοσης του, το LightGCN χρησιμοποιείται ως το βασικό GNN μοντέλο της παρούσας εργασίας.

Self-Supervised Learning

Ένα σημαντικό πρόβλημα στα recommender systems είναι η αραιότητα των δεδομένων (data sparsity). Πολλοί χρήστες διαθέτουν ελάχιστες αλληλεπιδράσεις, γεγονός που δυσκολεύει την εκμάθηση αξιόπιστων embeddings.

Το Self-Supervised Learning (SSL) αποτελεί μία σύγχρονη προσέγγιση αντιμετώπισης του προβλήματος αυτού. Η βασική ιδέα είναι η δημιουργία διαφορετικών views του ίδιου γράφου ή των ίδιων embeddings και η εκπαίδευση του μοντέλου ώστε οι αναπαραστάσεις του ίδιου κόμβου να παραμένουν παρόμοιες μεταξύ των διαφορετικών views.

Στην πράξη, το Self-Supervised Learning υλοποιείται συχνά μέσω contrastive learning, όπου το μοντέλο εκπαιδεύεται να διατηρεί συνεπείς αναπαραστάσεις για διαφορετικές εκδοχές των ίδιων δεδομένων. Με τον τρόπο αυτό παράγονται πιο ανθεκτικά και γενικεύσιμα embeddings.

Graph Augmentations και Embedding Perturbations

Η δημιουργία των διαφορετικών views μπορεί να πραγματοποιηθεί με διάφορους τρόπους. Η πρώτη κατηγορία αφορά graph augmentations. Χαρακτηριστικό παράδειγμα αποτελεί το Edge Dropout, όπου αφαιρείται τυχαία ένα ποσοστό ακμών από τον γράφο. Το μοντέλο εκπαιδεύεται ώστε οι αναπαραστάσεις των κόμβων να παραμένουν σταθερές παρά τις μικρές αλλαγές στη δομή του γράφου.

Η δεύτερη κατηγορία αφορά embedding perturbations. Αντί να μεταβάλλεται ο γράφος, προστίθεται μικρός θόρυβος στα embeddings των κόμβων. Η προσέγγιση αυτή χρησιμοποιείται από μεθόδους όπως το SimGCL και παρουσιάζει σημαντικά χαμηλότερο υπολογιστικό κόστος, καθώς δεν απαιτεί την κατασκευή πολλαπλών παραλλαγών του γράφου.

Μεθοδολογία

Αναπαράσταση Δεδομένων ως Διμερής Γράφος

Στην παρούσα εργασία το πρόβλημα της σύστασης μοντελοποιείται ως πρόβλημα πρόβλεψης συνδέσεων (link prediction) σε έναν διμερή γράφο χρηστών - αντικειμένων. Ο γράφος ορίζεται ως $G = (U, I, E)$ όπου:

- U είναι το σύνολο των χρηστών,
- I είναι το σύνολο των αντικειμένων (ταινιών),
- E είναι το σύνολο των αλληλεπιδράσεων μεταξύ χρηστών και αντικειμένων.

Κάθε ακμή $(u, i) \in E$ αντιστοιχεί σε μία θετική αλληλεπίδραση μεταξύ ενός χρήστη και ενός αντικειμένου. Στα πειράματα χρησιμοποιήθηκαν μόνο ratings μεγαλύτερα ή ίσα του 4, τα οποία θεωρήθηκαν θετικά σήματα προτίμησης.

Ο γράφος θεωρείται μη κατευθυνόμενος, καθώς η αλληλεπίδραση μεταξύ χρήστη και αντικειμένου αντιμετωπίζεται ως αμφίδρομη σύνδεση για τους σκοπούς της διάδοσης πληροφορίας στο LightGCN.

Διαχωρισμός Εκπαίδευσης και Αξιολόγησης

Για κάθε χρήστη διατηρήθηκε μία θετική αλληλεπίδραση στο σύνολο ελέγχου (test set), ενώ όλες οι υπόλοιπες θετικές αλληλεπιδράσεις χρησιμοποιήθηκαν για εκπαίδευση.

Η διαδικασία αυτή προσομοιώνει ένα ρεαλιστικό recommendation scenario, όπου το μοντέλο καλείται να προβλέψει μία μελλοντική προτίμηση του χρήστη με βάση το ιστορικό του.

Κατά την αξιολόγηση εφαρμόστηκε negative sampling. Για κάθε θετικό αντικείμενο του test set δημιουργήθηκαν 99 τυχαία αρνητικά αντικείμενα και το μοντέλο έπρεπε να κατατάξει το πραγματικό θετικό αντικείμενο μεταξύ 100 υποψηφίων.

Η προσέγγιση αυτή εξασφαλίζει ότι το μοντέλο καλείται να προβλέψει πραγματικά μη παρατηρημένες αλληλεπιδράσεις, προσομοιώνοντας ρεαλιστικά το πρόβλημα των συστάσεων.

Αρχιτεκτονική LightGCN

Το βασικό μοντέλο της εργασίας είναι το LightGCN.

Αρχικά, σε κάθε χρήστη και κάθε αντικείμενο αντιστοιχίζεται ένα εκπαιδευσιμο embedding διάστασης 64.

Σε κάθε propagation layer, κάθε κόμβος ενημερώνει την αναπαράστασή του λαμβάνοντας πληροφορία από τους γειτονικούς του κόμβους.

Μετά από (L) επίπεδα διάδοσης, τα embeddings όλων των επιπέδων συνδυάζονται μέσω averaging:

$$e_u = \frac{1}{L+1} \sum_{k=0}^L e_u^{(k)}, e_i = \frac{1}{L+1} \sum_{k=0}^L e_i^{(k)},$$
 όπου $e_u^{(k)}$ και $e_i^{(k)}$ είναι τα embeddings του χρήστη και του αντικειμένου στο επίπεδο k .

Στην παρούσα εργασία χρησιμοποιήθηκαν τρία propagation layers και embedding dimension ίσο με 64.

Η τελική συνάφεια μεταξύ ενός χρήστη u και ενός αντικειμένου i υπολογίζεται μέσω του εσωτερικού γινομένου των τελικών embeddings $\hat{y}_{ui} = e_u^T e_i$.

Υψηλότερες τιμές του $\hat{y}_{ui}$ αντιστοιχούν σε μεγαλύτερη πιθανότητα ο χρήστης να ενδιαφέρεται για το συγκεκριμένο αντικείμενο.

Bayesian Personalized Ranking Loss

Η εκπαίδευση όλων των μοντέλων βασίστηκε στη συνάρτηση κόστους Bayesian Personalized Ranking (BPR).

Για κάθε χρήστη επιλέγεται ένα θετικό αντικείμενο i και ένα αρνητικό αντικείμενο j , με στόχο το μοντέλο να αποδίδει υψηλότερο score στο θετικό αντικείμενο $\hat{y}_{ui} > \hat{y}_{uj}$.

Η BPR loss ορίζεται ως: $L_{BPR} = - \sum_{(u,i,j)} \log \sigma(\hat{y}_{ui} - \hat{y}_{uj})$, όπου $\sigma(\cdot)$ είναι η sigmoid συνάρτηση.

Η συγκεκριμένη loss είναι ιδιαίτερα δημοφιλής στα recommender systems καθώς βελτιστοποιεί άμεσα τη σχετική κατάταξη των αντικειμένων αντί για την πρόβλεψη απόλυτων ratings.

Self-Supervised Learning Framework

Πέρα από τη βασική recommendation loss, εξετάστηκαν και self-supervised learning στρατηγικές βασισμένες σε contrastive learning.

Η βασική ιδέα του SSL είναι η δημιουργία βοηθητικών μαθησιακών στόχων απευθείας από τα διαθέσιμα δεδομένα, χωρίς την ανάγκη πρόσθετων labels. Με τον τρόπο αυτό το μοντέλο αποκτά επιπλέον εποπτεία κατά την εκπαίδευση και μπορεί να μάθει πιο ανθεκτικές και γενικεύσιμες αναπαραστάσεις.

Στην παρούσα εργασία εξετάζονται self-supervised στρατηγικές βασισμένες σε διαφορετικούς μηχανισμούς δημιουργίας views, είτε μέσω graph augmentations είτε μέσω embedding perturbations.

Contrastive Learning

Για κάθε augmentation παράγονται δύο διαφορετικά views του ίδιου γράφου ή των ίδιων embeddings. Οι αναπαραστάσεις του ίδιου κόμβου στα δύο views θεωρούνται positive pairs, ενώ οι αναπαραστάσεις διαφορετικών κόμβων λειτουργούν ως negative pairs.

Στόχος του contrastive learning είναι η μεγιστοποίηση της ομοιότητας μεταξύ των positive pairs και η ελαχιστοποίηση της ομοιότητας με τα negative pairs, οδηγώντας σε πιο σταθερές και γενικεύσιμες αναπαραστάσεις.

Διαδικασία Εκπαίδευσης

Όλα τα μοντέλα εκπαιδεύτηκαν χρησιμοποιώντας mini-batch training και τον Adam optimizer. Για κάθε θετική αλληλεπίδραση δημιουργούνταν δυναμικά ένα αρνητικό παράδειγμα μέσω negative sampling.

Στην περίπτωση του βασικού LightGCN, η εκπαίδευση βασίστηκε αποκλειστικά στη BPR loss. Για τα SSL-based μοντέλα χρησιμοποιήθηκε η συνδυαστική συνάρτηση κόστους $L = L_{BPR} + \lambda L_{SSL}$,

όπου:

- L_{BPR} είναι η βασική συνάρτηση κατάταξης του LightGCN,
- L_{SSL} είναι η contrastive loss, και

- λ είναι μία υπερπαράμετρος που καθορίζει τη σχετική συμβολή του SSL κατά την εκπαίδευση.

Η εκπαίδευση πραγματοποιήθηκε για 50 epochs και η απόδοση αξιολογήθηκε μέσω των μετρικών HR@10, Recall@10 και NDCG@10.

Με τον συνδυασμό supervised και self-supervised εκπαίδευσης το μοντέλο αξιοποιεί αποτελεσματικότερα τη δομή του γράφου και μπορεί να παράγει αναπαραστάσεις υψηλότερης ποιότητας, ιδιαίτερα σε περιπτώσεις αραιών δεδομένων.

SSL Μέθοδοι και Προτεινόμενες Επεκτάσεις

Edge Dropout SSL

Η πρώτη self-supervised μέθοδος που εξετάστηκε βασίζεται στο Edge Dropout. Η ιδέα είναι η δημιουργία δύο διαφορετικά views του ίδιου γράφου μέσω τυχαίας αφαίρεσης ακμών. Για κάθε epoch δημιουργούνται δύο νέοι γράφοι: $G_1 = (U, I, E_1)$, $G_2 = (U, I, E_2)$, όπου κάθε ακμή διατηρείται με πιθανότητα $(1-p)$, ενώ αφαιρείται με πιθανότητα (p) .

Το ίδιο μοντέλο εφαρμόζεται και στους δύο γράφους και παράγονται δύο διαφορετικές αναπαραστάσεις για κάθε χρήστη και αντικείμενο.

Στη συνέχεια εφαρμόζεται contrastive learning ώστε οι αναπαραστάσεις του ίδιου κόμβου στα δύο views να συγκλίνουν.

Η μέθοδος αυτή αποτελεί μία από τις πιο δημοφιλείς graph-based SSL προσεγγίσεις και χρησιμοποιείται ως βασικό self-supervised baseline στην εργασία.

SimGCL-Style Embedding Perturbation

Η δεύτερη baseline SSL προσέγγιση βασίζεται στη λογική του SimGCL. Σε αντίθεση με το Edge Dropout, ο γράφος παραμένει αμετάβλητος και η διαφοροποίηση των views πραγματοποιείται απευθείας πάνω στα embeddings. Συγκεκριμένα, προστίθεται τυχαίος κανονικοποιημένος θόρυβος: $e' = e + \epsilon \cdot noise$, όπου:

- e είναι το αρχικό embedding,
- $noise$ είναι τυχαίο κανονικοποιημένο διάνυσμα,
- ϵ είναι η ένταση του perturbation.

Με αυτόν τον τρόπο δημιουργούνται 2 διαφορετικές αναπαραστάσεις του ίδιου κόμβου χωρίς να απαιτείται η κατασκευή πολλαπλών γραφημάτων. Η προσέγγιση αυτή παρουσιάζει σημαντικά μικρότερο υπολογιστικό κόστος σε σχέση με τις graph augmentation τεχνικές.

Popularity-Aware Edge Dropout (Proposed)

Η πρώτη προτεινόμενη μέθοδος της εργασίας επεκτείνει το κλασικό Edge Dropout. Στο τυπικό Edge Dropout όλες οι ακμές έχουν την ίδια πιθανότητα αφαίρεσης. Ωστόσο, στα recommender systems υπάρχουν αντικείμενα με πολύ διαφορετική δημοτικότητα. Ορισμένα αντικείμενα εμφανίζονται σε μεγάλο αριθμό αλληλεπιδράσεων, ενώ άλλα είναι ιδιαίτερα σπάνια.

Η βασική υπόθεση είναι ότι η αφαίρεση ακμών από δημοφιλή αντικείμενα είναι λιγότερο καταστροφική, καθώς υπάρχει ήδη μεγάλη ποσότητα διαθέσιμης πληροφορίας.

Για τον λόγο αυτό εισάγεται ένας popularity-aware μηχανισμός: $p_i = p_{base} \cdot f(popularity_i)$, όπου η πιθανότητα αφαίρεσης κάθε ακμής εξαρτάται από τη δημοτικότητα του αντίστοιχου αντικειμένου.

Με αυτόν τον τρόπο οι ακμές δημοφιλών αντικειμένων αφαιρούνται συχνότερα, ενώ οι ακμές σπάνιων αντικειμένων προστατεύονται περισσότερο κατά τη διαδικασία augmentation.

Degree-Adaptive Noise Injection (Proposed)

Η κύρια προτεινόμενη συνεισφορά της εργασίας είναι η εισαγωγή ενός adaptive μηχανισμού perturbation στα embeddings. Η βασική ιδέα είναι ότι οι κόμβοι με διαφορετικό βαθμό δεν πρέπει να δέχονται τον ίδιο θόρυβο. Οι χρήστες και τα αντικείμενα με πολλές αλληλεπιδράσεις διαθέτουν συνήθως πιο σταθερές αναπαραστάσεις, ενώ οι sparse κόμβοι βασίζονται σε πολύ λιγότερη πληροφορία. Για τον λόγο αυτό, η ένταση του perturbation πρέπει να προσαρμόζεται δυναμικά: $\epsilon_v = \epsilon_{base} \cdot s(v)$, όπου $s(v)$ είναι συνάρτηση του βαθμού του κόμβου. Συγκεκριμένα, μελετήθηκαν δύο διαφορετικές παραλλαγές:

Dense-Aware Noise Οι κόμβοι με υψηλό βαθμό λαμβάνουν μεγαλύτερο perturbation. Η λογική είναι ότι οι dense κόμβοι μπορούν να αντέξουν μεγαλύτερες μεταβολές χωρίς να χάσουν σημαντική πληροφορία.

Sparse-Aware Noise Οι κόμβοι με χαμηλό βαθμό λαμβάνουν μεγαλύτερο perturbation. Η υπόθεση εδώ είναι ότι οι sparse κόμβοι μπορούν να ωφεληθούν περισσότερο από επιπλέον regularization.

Οι δύο αυτές στρατηγικές επιτρέπουν τη διερεύνηση της σχέσης μεταξύ sparsity και self-supervised perturbations.

Combined Adaptive SSL (Proposed)

Τέλος, εξετάστηκε ένας συνδυασμός των δύο προτεινόμενων ιδεών. Συγκεκριμένα, χρησιμοποιήθηκε ταυτόχρονα:

- Popularity-Aware Edge Dropout στο επίπεδο του γράφου.
- Degree-Adaptive Noise Injection στο επίπεδο των embeddings.

Η συγκεκριμένη μέθοδος επιχειρεί να αξιοποιήσει τόσο δομικές μεταβολές του γράφου όσο και perturbations στις αναπαραστάσεις των κόμβων.

Στόχος του πειράματος ήταν να διερευνηθεί κατά πόσο οι δύο adaptive μηχανισμοί μπορούν να λειτουργήσουν συμπληρωματικά και να προσφέρουν επιπλέον βελτίωση στην απόδοση του recommender system.

Πειραματική Μελέτη

Datasets

Για την αξιολόγηση των προτεινόμενων μεθόδων χρησιμοποιήθηκαν δύο ευρέως διαδεδομένα datasets συστάσεων, τα MovieLens 100K και MovieLens 1M.

Το MovieLens 100K περιλαμβάνει περίπου 100.000 ratings από 943 χρήστες σε 1.682 ταινίες, ενώ το MovieLens 1M περιλαμβάνει περίπου 1 εκατομμύριο ratings από 6.040 χρήστες σε 3.706 ταινίες.

Στην παρούσα εργασία υιοθετήθηκε το πρωτόκολλο implicit feedback. Συγκεκριμένα, ratings μεγαλύτερα ή ίσα του 4 θεωρήθηκαν θετικές αλληλεπιδράσεις, ενώ οι υπόλοιπες αξιολογήσεις αγνοήθηκαν.

Για κάθε χρήστη διατηρήθηκε μία θετική αλληλεπίδραση στο test set, ενώ όλες οι υπόλοιπες χρησιμοποιήθηκαν για εκπαίδευση. Με τον τρόπο αυτό προσομοιώνεται ένα ρεαλιστικό recommendation scenario, όπου το μοντέλο καλείται να προβλέψει μία μελλοντική προτίμηση του χρήστη.

Πρωτόκολλο Αξιολόγησης

Η αξιολόγηση πραγματοποιήθηκε με τη χρήση negative sampling. Για κάθε θετικό αντικείμενο του test set δημιουργήθηκαν 99 τυχαία αρνητικά αντικείμενα, σχηματίζοντας ένα σύνολο 100 υποψηφίων αντικειμένων.

Το μοντέλο παρήγαγε score για κάθε υποψήφιο αντικείμενο και στη συνέχεια πραγματοποιήθηκε κατάταξη με βάση τα προβλεπόμενα scores.

Χρησιμοποιήθηκαν οι ακόλουθες μετρικές αξιολόγησης:

- Hit Ratio@10 (HR@10): μετρά το ποσοστό των περιπτώσεων όπου το πραγματικό αντικείμενο εμφανίζεται στις πρώτες 10 θέσεις της κατάταξης,
- Recall@10: εκφράζει το ποσοστό των σχετικών αντικειμένων που ανακτώνται στις πρώτες 10 θέσεις, και
- Normalized Discounted Cumulative Gain@10 (NDCG@10): λαμβάνει υπόψη όχι μόνο την ύπαρξη του σωστού αντικειμένου στο Top-10, αλλά και τη θέση στην οποία εμφανίζεται, δίνοντας μεγαλύτερη βαρύτητα στις υψηλότερες θέσεις της κατάταξης.

Model Configuration

Όλα τα μοντέλα εκπαιδεύτηκαν χρησιμοποιώντας embeddings διάστασης 64. Για το LightGCN χρησιμοποιήθηκαν 3 propagation layers, όπως προτείνεται στη σχετική βιβλιογραφία. Η εκπαίδευση πραγματοποιήθηκε για 50 epochs χρησιμοποιώντας τον Adam optimizer με learning rate $lr = 10^{-3}$, ενώ εφαρμόστηκε επίσης L_2 regularization με συντελεστή $\lambda_{reg} = 10^{-4}$.

Για όλα τα SSL-based μοντέλα η συνολική συνάρτηση κόστους ορίστηκε ως $L = L_{BPR} + \lambda_{SSL} L_{SSL}$, όπου L_{BPR} είναι η recommendation loss και L_{SSL} η contrastive loss.

Hyperparameter Selection

Πραγματοποιήθηκε περιορισμένη αναζήτηση υπερπαραμέτρων στο MovieLens 100K dataset.

Για το Edge SSL εξετάστηκαν διαφορετικοί συνδυασμοί:

- $\lambda_{SSL} \in \{0.005, 0.01, 0.05\}$
- Drop Rate $\in \{0.1, 0.2, 0.3\}$

Για το SimGCL εξετάστηκαν:

- $\lambda_{SSL} \in \{0.005, 0.01, 0.05\}$
- Noise Magnitude $\in \{0.05, 0.1, 0.2\}$

Οι καλύτερες υπερπαραμέτροι που προέκυψαν από τα πειράματα χρησιμοποιήθηκαν στη συνέχεια για την αξιολόγηση των τελικών μοντέλων και για τα πειράματα στο MovieLens 1M χωρίς επιπλέον tuning.

Οι τελικές υπερπαραμέτροι που χρησιμοποιήθηκαν στα πειράματα παρουσιάζονται στον παρακάτω πίνακα.

Parameter	Value
Embedding Dimension	64
Propagation Layers	3
Learning Rate	0.001
Weight Decay	10^{-4}
Epochs	50
Batch Size	2048

Sparsity Analysis

Προκειμένου να μελετηθεί η συμπεριφορά των μοντέλων υπό διαφορετικά επίπεδα αραιότητας, πραγματοποιήθηκε επιπλέον ανάλυση στο MovieLens 100K.

Συγκεκριμένα, διατηρήθηκε μόνο ένα ποσοστό των αρχικών αλληλεπιδράσεων εκπαίδευσης:

- 100% των αλληλεπιδράσεων
- 50% των αλληλεπιδράσεων
- 25% των αλληλεπιδράσεων
- 10% των αλληλεπιδράσεων

Με τον τρόπο αυτό αξιολογήθηκε η ανθεκτικότητα των διαφόρων SSL στρατηγικών σε όλο και πιο αραιά σενάρια συστάσεων.

Λόγω του σημαντικά αυξημένου υπολογιστικού κόστους, το MovieLens 1M χρησιμοποιήθηκε ως generalization benchmark, και όχι για πλήρη sparsity analysis.

Αποτελέσματα & Συζήτηση

Βασικά συμπεράσματα για MovieLens 100K

Αρχικά συγκρίθηκαν τα βασικά μοντέλα recommendation καθώς και οι self-supervised παραλλαγές τους στο MovieLens 100K dataset.

Πίνακας 1: Main Results on MovieLens 100K

Method	HR@10	NDCG@10
BPR-MF	0.585	0.332
LightGCN	0.575	0.315
Edge SSL	0.625	0.359
SimGCL	0.622	0.350
Adaptive Noise Dense	0.618	0.353

Παρατηρούμε ότι όλες οι SSL-based μέθοδοι υπερέχουν σημαντικά τόσο του BPR-MF, όσο και του βασικού LightGCN.

Η καλύτερη συνολική επίδοση επιτυγχάνεται από το Edge SSL, το οποίο εμφανίζει HR@10 ίσο με 0.625 και NDCG@10 ίσο με 0.359. Το αποτέλεσμα αυτό υποδεικνύει ότι η δημιουργία πολλαπλών graph views μέσω Edge Dropout προσφέρει αποτελεσματικό regularization και οδηγεί σε πιο γενικεύσιμες αναπαραστάσεις.

Παράλληλα, τόσο το SimGCL όσο και το Adaptive Noise Dense πετυχαίνουν παρόμοια επίπεδα απόδοσης, επιβεβαιώνοντας ότι τα embedding perturbations αποτελούν μία ιδιαίτερα ανταγωνιστική εναλλακτική προσέγγιση έναντι των graph augmentations.

Υπερπαράμετροι

Για το Edge SSL πραγματοποιήθηκε διερεύνηση διαφορετικών τιμών του SSL weight και του Drop Rate.

Τα αποτελέσματα έδειξαν ότι οι μεγαλύτερες τιμές του SSL weight οδηγούν σε καλύτερη απόδοση, με την καλύτερη διαμόρφωση να αντιστοιχεί σε $\lambda_{SSL} = 0.05$ και $drop\ rate = 0.2$.

Η συγκεκριμένη ρύθμιση πέτυχε την υψηλότερη τιμή NDCG@10.

Για το SimGCL εξετάστηκαν διαφορετικές τιμές θορύβου και SSL weight. Τα αποτελέσματα έδειξαν ότι σχετικά ήπια perturbations ($\epsilon = 0.05$) σε συνδυασμό με μέτριο contrastive regularization ($\lambda_{SSL} = 0.01$) παρήγαγαν τις καλύτερες επιδόσεις.

Το εύρημα αυτό είναι λογικό, καθώς στο SimGCL το perturbation εφαρμόζεται απευθείας σε κάθε embedding σε κάθε epoch. Επομένως η χρήση υπερβολικά ισχυρού contrastive signal μπορεί να οδηγήσει σε υπερβολικό regularization και απώλεια χρήσιμης πληροφορίας.

Αξιολόγηση των Προτεινόμενων Μεθόδων

Στη συνέχεια αξιολογήθηκαν οι προτεινόμενες adaptive παραλλαγές.

Πίνακας 2: Results of Proposed Methods

Method	HR@10	NDCG@10
Popularity-Aware Edge SSL	0.612	0.359
Adaptive Noise Dense	0.618	0.353
Adaptive Noise Sparse	0.616	0.350
Combined Adaptive SSL	0.617	0.356

Η μέθοδος Popularity-Aware Edge SSL πέτυχε παρόμοια απόδοση με το κλασικό Edge SSL, χωρίς όμως να παρουσιάσει σταθερή βελτίωση.

Αντίθετα, η οικογένεια των Adaptive Noise μεθόδων εμφάνισε ιδιαίτερο ενδιαφέρον. Η Dense-Aware παραλλαγή παρουσίασε σταθερά υψηλή απόδοση, ενώ η Sparse-Aware εκδοχή δεν κατάφερε να ξεπεράσει τα baseline SSL μοντέλα.


Τέλος, ο συνδυασμός των δύο adaptive μηχανισμών (Combined Adaptive SSL) πέτυχε ανταγωνιστικά αποτελέσματα, χωρίς όμως να υπερβεί την καλύτερη επίδοση του Edge SSL στο MovieLens 100K.

Sparsity Analysis


Προκειμένου να μελετηθεί η συμπεριφορά των μοντέλων σε συνθήκες περιορισμένων αλληλεπιδράσεων, πραγματοποιήθηκε επιπλέον ανάλυση αραιότητας στο MovieLens 100K.

Πίνακας 3: Best Methods under Different Sparsity Levels

Sparsity	Best Method	NDCG@10
100%	Edge SSL	0.355
50%	Adaptive Noise Dense	0.287
25%	SimGCL	0.257
10%	LightGCN	0.178



Σχήμα 1: HR@10 under different sparsity levels on MovieLens 100K



Σχήμα 2: NDCG@10 under different sparsity levels on MovieLens 100K

Όπως φαίνεται τόσο στον πίνακα 3 όσο και στα σχήματα 1 και 2, παρατηρείται μία σαφής μεταβολή στη συμπεριφορά των μοντέλων καθώς αυξάνεται η αραιότητα του γράφου.

Στο πλήρες dataset, το Edge SSL αποτελεί την καλύτερη επιλογή. Ωστόσο, όταν μειώνεται ο αριθμός των διαθέσιμων αλληλεπιδράσεων, οι embedding-based προσεγγίσεις γίνονται περισσότερο ανταγωνιστικές.

Στο 50% και 25% των διαθέσιμων αλληλεπιδράσεων, το Adaptive Noise Dense και το SimGCL επιτυγχάνουν τις υψηλότερες επιδόσεις αντίστοιχα. Το αποτέλεσμα αυτό υποδηλώνει ότι τα perturbation-based SSL σχήματα είναι περισσότερο ανθεκτικά σε μέτρια επίπεδα sparsity.

Αντίθετα, σε ακραίες συνθήκες αραιότητας (10%) όλες οι SSL μέθοδοι παρουσιάζουν αισθητή πτώση της απόδοσης και το απλό LightGCN αναδεικνύεται ως η πιο σταθερή

προσέγγιση. Το εύρημα αυτό υποδηλώνει ότι όταν οι διαθέσιμες αλληλεπιδράσεις είναι εξαιρετικά περιορισμένες, το contrastive signal μπορεί να γίνει λιγότερο αξιόπιστο.

Generalization Study σε MovieLens 1M

Για την αξιολόγηση της δυνατότητας γενίκευσης των μοντέλων πραγματοποιήθηκε επιπλέον πειραματική μελέτη στο σημαντικά μεγαλύτερο MovieLens 1M dataset.

Πίνακας 4: Generalization Results on MovieLens 1M

Method	HR@10	NDCG@10	Runtime (min)
BPR-MF	0.679	0.395	2.9
LightGCN	0.652	0.376	77.7
Edge SSL	0.664	0.401	230.9
SimGCL	0.694	0.411	109.2
Adaptive Noise Dense	0.696	0.412	106.3

Σε αντίθεση με το MovieLens 100K, όπου το Edge SSL πέτυχε την υψηλότερη επίδοση, στο μεγαλύτερο dataset η καλύτερη συνολική μέθοδος είναι η Adaptive Noise Dense.

Η παρατήρηση αυτή υποδηλώνει ότι η προσαρμογή της έντασης του perturbation με βάση τον βαθμό των κόμβων αξιοποιεί αποτελεσματικότερα τη δομή μεγαλύτερων και πυκνότερων γραφημάτων.

Παράλληλα, το SimGCL εμφανίζει σχεδόν ισοδύναμη απόδοση με την Adaptive Noise Dense, επιβεβαιώνοντας την αποτελεσματικότητα των embedding-level augmentations.

Επιπλέον, το Edge SSL εμφανίζει υπερδιπλάσιο χρόνο εκπαίδευσης σε σχέση με τα SimGCL και Adaptive Noise Dense, χωρίς να προσφέρει αντίστοιχη βελτίωση στην απόδοση. Συνεπώς, οι embedding perturbation μέθοδοι φαίνεται να προσφέρουν καλύτερο συμβιβασμό μεταξύ ποιότητας συστάσεων και υπολογιστικού κόστους.

Additional Sparsity Validation on MovieLens 1M


Προκειμένου να επιβεβαιωθούν τα συμπεράσματα της sparsity analysis σε μεγαλύτερη κλίμακα, πραγματοποιήθηκε ένα επιπλέον πείραμα στο MovieLens 1M χρησιμοποιώντας μόνο το 50% των διαθέσιμων αλληλεπιδράσεων εκπαίδευσης.

Πίνακας 5: MovieLens 1M - 50% Sparsity

Method	HR@10	NDCG@10	Runtime (min)
LightGCN	0.563	0.308	20.9
Edge SSL	0.587	0.326	84.3
SimGCL	0.618	0.347	44.9
Adaptive Noise Dense	0.620	0.345	73.1

Τα αποτελέσματα επιβεβαιώνουν την τάση που παρατηρήθηκε στο MovieLens 100K. Καθώς μειώνεται η ποσότητα των διαθέσιμων αλληλεπιδράσεων, οι embedding-based SSL μέθοδοι εμφανίζουν μεγαλύτερη ανθεκτικότητα σε σχέση με τις graph augmentation προσεγγίσεις.

Το SimGCL πέτυχε την υψηλότερη τιμή NDCG@10, ενώ η Adaptive Noise Dense παρουσίασε το υψηλότερο HR@10. Τα αποτελέσματα αυτά υποδηλώνουν ότι οι δύο embedding-based SSL μέθοδοι εμφανίζουν ιδιαίτερα ανταγωνιστική συμπεριφορά σε sparse recommendation scenarios μεγάλης κλίμακας.



Σχήμα 3: Trade-off between recommendation quality and training cost on MovieLens 1M

Το Σχήμα 3 παρουσιάζει τη σχέση μεταξύ ποιότητας συστάσεων και υπολογιστικού κόστους στο MovieLens 1M. Φαίνεται ότι το Edge SSL απαιτεί σημαντικά μεγαλύτερο χρόνο εκπαίδευσης χωρίς αντίστοιχη βελτίωση στην απόδοση. Αντίθετα, οι μέθοδοι SimGCL και Adaptive Noise Dense επιτυγχάνουν τις υψηλότερες τιμές NDCG@10 με αισθητά μικρότερο υπολογιστικό κόστος, γεγονός που τις καθιστά πιο αποδοτικές επιλογές για μεγάλης κλίμακας recommender systems.

Key Findings

Τα βασικά συμπεράσματα που προέκυψαν από τα πειράματα συνοψίζονται ως εξής:

- Οι Self-Supervised Learning τεχνικές βελτιώνουν σημαντικά την απόδοση του βασικού LightGCN. Στο πλήρες MovieLens 100K, οι SSL-based μέθοδοι πέτυχαν υψηλότερες τιμές HR@10 και NDCG@10 σε σχέση με το βασικό LightGCN.
- Το Edge SSL πέτυχε την καλύτερη συνολική επίδοση στο MovieLens 100K, επιβεβαιώνοντας ότι τα graph augmentations αποτελούν αποτελεσματικό μηχανισμό regularization για graph-based recommender systems.
- Οι embedding perturbation μέθοδοι (SimGCL και Adaptive Noise) εμφάνισαν μεγαλύτερη ανθεκτικότητα σε περιβάλλοντα μέτριας αραιότητας. Στα επίπεδα 50% και 25% των διαθέσιμων αλληλεπιδράσεων πέτυχαν καλύτερα αποτελέσματα από τις graph-based SSL προσεγγίσεις.
- Σε ακραίες συνθήκες αραιότητας (10% των διαθέσιμων αλληλεπιδράσεων), οι SSL μέθοδοι παρουσίασαν σημαντική πτώση της απόδοσης, γεγονός που υποδηλώνει ότι η αποτελεσματικότητα του contrastive signal μειώνεται όταν η διαθέσιμη πληροφορία στον γράφο είναι εξαιρετικά περιορισμένη.
- Η Adaptive Noise Dense μέθοδος παρουσίασε την καλύτερη συνολική επίδοση στο πλήρες MovieLens 1M, ενώ το SimGCL αναδείχθηκε ως η ισχυρότερη μέθοδος στο επιπλέον πείραμα 50% sparsity του MovieLens 1M. Το αποτέλεσμα αυτό ενισχύει την υπόθεση ότι οι embedding-based SSL προσεγγίσεις γενικεύονται αποτελεσματικότερα σε sparse recommendation scenarios μεγάλης κλίμακας.
- Οι embedding-based SSL προσεγγίσεις παρουσίασαν σημαντικά χαμηλότερο υπολογιστικό κόστος σε σχέση με το Edge SSL. Παράλληλα, πέτυχαν ισοδύναμη ή και καλύτερη απόδοση στο μεγαλύτερο dataset, προσφέροντας καλύτερο συμβιβασμό μεταξύ ποιότητας συστάσεων και χρόνου εκπαίδευσης.
- Η προσαρμογή της έντασης του perturbation με βάση τον βαθμό των κόμβων αποτελεί μία πολλά υποσχόμενη κατεύθυνση για τη βελτίωση των SSL recommender systems, ιδιαίτερα σε μεγάλης κλίμακας datasets.

Συμπεράσματα

Συνολικά, τα αποτελέσματα δείχνουν ότι η επιλογή της κατάλληλης SSL στρατηγικής εξαρτάται σε σημαντικό βαθμό από τα χαρακτηριστικά του dataset και το επίπεδο αραιότητας των διαθέσιμων αλληλεπιδράσεων.

Ενώ οι graph-based augmentations αποδείχθηκαν ιδιαίτερα αποτελεσματικές στο πλήρες MovieLens 100K dataset, οι embedding-based perturbation προσεγγίσεις παρουσίασαν καλύτερη δυνατότητα γενίκευσης σε μεγαλύτερης κλίμακας recommendation προβλήματα. Η παρατήρηση αυτή υποδηλώνει ότι η άμεση τροποποίηση των embeddings αποτελεί μία αποδοτική εναλλακτική λύση έναντι των πιο υπολογιστικά απαιτητικών graph augmentation τεχνικών.

Ιδιαίτερα ενθαρρυντικά ήταν τα αποτελέσματα της προτεινόμενης Degree-Adaptive Noise Injection μεθόδου, τα οποία δείχνουν ότι η αξιοποίηση δομικών χαρακτηριστικών του γράφου κατά τον σχεδιασμό των augmentations μπορεί να οδηγήσει σε πιο αποτελεσματικά self-supervised recommendation μοντέλα.

Περιορισμοί

Παρότι τα αποτελέσματα είναι ιδιαίτερα ενθαρρυντικά, η παρούσα εργασία παρουσιάζει ορισμένους περιορισμούς. Αρχικά, τα πειράματα πραγματοποιήθηκαν αποκλειστικά σε datasets κινηματογραφικών προτιμήσεων (MovieLens), γεγονός που περιορίζει την άμεση γενίκευση των συμπερασμάτων σε άλλους τομείς εφαρμογής, όπως ηλεκτρονικό εμπόριο, μουσική ή κοινωνικά δίκτυα. Επιπλέον, η αξιολόγηση βασίστηκε σε ένα συγκεκριμένο train-test split και σε fixed negative sampling protocol. Διαφορετικά πρωτόκολλα αξιολόγησης ενδέχεται να επηρεάσουν τις απόλυτες τιμές των μετρικών.

Τέλος, εξετάστηκε μόνο το LightGCN ως βασική αρχιτεκτονική recommendation. Αν και αποτελεί μία από τις πιο διαδεδομένες μεθόδους της βιβλιογραφίας, τα συμπεράσματα ενδέχεται να διαφοροποιούνται σε πιο σύνθετες GNN αρχιτεκτονικές.

Μελλοντική Εργασία

Μία ενδιαφέρουσα κατεύθυνση για μελλοντική έρευνα είναι η εφαρμογή των προτεινόμενων adaptive SSL τεχνικών σε μεγαλύτερα και πιο ετερογενή recommendation datasets.

Επιπλέον, θα μπορούσε να μελετηθεί η χρήση πιο σύνθετων degree-aware ή popularity-aware συναρτήσεων, οι οποίες να προσαρμόζουν δυναμικά όχι μόνο την ένταση του perturbation αλλά και τη μορφή του augmentation κατά τη διάρκεια της εκπαίδευσης.

Μία ακόμη πιθανή επέκταση αφορά την ενσωμάτωση επιπλέον features (πχ content features), όπως χαρακτηριστικά χρηστών ή αντικειμένων, σε ένα multimodal recommendation framework.

Τέλος, ιδιαίτερο ενδιαφέρον παρουσιάζει η διερεύνηση των προτεινόμενων adaptive perturbation στρατηγικών σε σύγχρονες SSL-based αρχιτεκτονικές recommender systems, προκειμένου να αξιολογηθεί κατά πόσο τα οφέλη τους γενικεύονται πέρα από το πλαίσιο του LightGCN.

Βιβλιογραφία

- [1] F. M. Harper and J. A. Konstan, “The MovieLens Datasets: History and Context,” *ACM Transactions on Interactive Intelligent Systems*, vol. 5, no. 4, pp. 1–19, 2015.
- [2] W. L. Hamilton, *Graph Representation Learning*. Morgan & Claypool Publishers, 2020.
- [3] D. Liben-Nowell and J. Kleinberg, “The Link Prediction Problem for Social Networks,” *Journal of the American Society for Information Science and Technology*, vol. 58, no. 7, pp. 1019–1031, 2007.